CORPORACIÓN UNIFICADA NACIONAL DE EDUCACIÓN SUPERIOR (CUN)
Escuela de Ingeniería | Especialización en Inteligencia Artificial
Asignatura: Computación en la Nube | **Docente:** Hamilton Rivera Flor

PROYECTO: ACA N° 1 - COMPUTACIÓN EN LA NUBE

Ingesta, Vectorización y Almacenamiento Vectorial en Clúster Cloud para Sistemas RAG

Guía oficial de requerimientos técnicos para la entrega acumulativa ACA 1. El proyecto se enfoca en el aprovisionamiento de infraestructura cloud de datos no estructurados, diseño de canalizaciones de chunking, generación de embeddings e indexación vectorial serverless con libertad de selección de herramientas y servicios gestionados gratuitos.

📌 SECCIÓN 1: ¿De qué se trata el proyecto? (Propósito y Pregunta Orientadora)

🎯 Objetivo General

Diseñar e implementar la arquitectura cloud de ingesta, fragmentación (chunking), generación de embeddings y almacenamiento semántico en una Base de Datos Vectorial gestionada en la nube (a elección del equipo: Qdrant Cloud, Pinecone, ChromaDB, Weaviate o Supabase pgvector), integrando metadatos de un dataset estructurado con un corpus complementario de documentos no estructurados (PDF/TXT) en sectores estratégicos (salud, educación o ventas).

❓ Pregunta Orientadora / Situación Problema

¿Cómo estructurar e implementar una canalización (pipeline) de datos no estructurados en la nube mediante bases de datos vectoriales serverless y modelos de embeddings abiertos, que permita indexar y recuperar semánticamente información contextual especializada con alta precisión, costo cero y baja latencia?

⚙️ Ecosistema Abierto de Herramientas y Opciones Cloud (Capa Gratuita)

Componente Arquitectónico	Opciones de Herramientas Permitidas	Flexibilidad y Recomendación
Base de Datos SQL y Vectorial	• Qdrant (Free Tier permanente 1GB) • Pinecone Serverless (Starter free tier) • Supabase pgvector (PostgreSQL serverless) • Weaviate Cloud (WCD Sandbox) / ChromaDB	Libertad de elección. Se recomienda Qdrant o Pinecone por facilidad de despliegue serverless y dashboard visual.
Modelo de Embeddings	• Sentence-Transformers (all-MiniLM-L6-v2, BGE-small, Multilingual-E5) Gemini embedings 2, EmbeddingGemma 2, qwen3-embedding • Google AI Studio API (text-embedding-004) • Cohere Embed v3 (API Developer Free)	Modelos locales HuggingFace (sin consumo de cuotas) o APIs cloud gratuitas con soporte nativo multilingüe/español. Modelos de texto o multimodales (Audio, texto, documentos, imagenes)
Entorno y Ejecución	• Google Colab (CPU/T4 GPU gratuita) • Kaggle Notebooks / Jupyter Lab local • Repositorio GitHub con scripts modulares	Uso de entornos de desarrollo locales o en nube, notebooks, etc

📊 SECCIÓN 2: Catálogo de Proyectos y Temáticas (3 Pilares)

> ⚡ **REGLA OBLIGATORIA: Complementación Documental para la Base Vectorial**
> Para construir la base de conocimiento vectorial del sistema RAG, el equipo debe seleccionar uno de los tres pilares y trabajar sobre un dataset base. Es obligatorio complementar dicho dataset con un corpus propio de documentos no estructurados (mínimo de 2 a 3 documentos en formato PDF, TXT o Markdown) afines al sector (guías clínicas, reglamentos, normativas, políticas comerciales o manuales técnicos). Dichos documentos serán fragmentados, vectorizados y consultados.

🩺 Proyecto 1: Salud	🎓 Proyecto 2: Educación	🛒 Proyecto 3: Ventas
Enfoque: **Asistente cloud de consulta clínica, diagnóstico asistido y protocolos médicos.**	**Enfoque:** **Asistente cloud de consulta académica, normatividad institucional y permanencia estudiantil.**	**Enfoque:** **Asistente cloud de atención comercial, soporte técnico y políticas de e-commerce.**
Modalidad: **Ingesta de guías médicas y literatura clínica cruzada con registros tabulares de pacientes.**	**Modalidad:** **Indexación de reglamentos estudiantiles, estatutos y lineamientos de bienestar universitario.**	**Modalidad:** **Indexación de manuales de producto, políticas de garantía, términos de servicio y reseñas.**
Datasets base disponibles: **• UCI Heart Disease** **• UCI Breast Cancer Wisconsin** **• Chest X-Ray Images (Pneumonia)** **• Skin Cancer MNIST: HAM10000**	**Datasets base disponibles:** **• UCI Predict Students Dropout** **• UCI Student Performance** **• Students Performance in Exams** **• xAPI-Edu-Data**	**Datasets base disponibles:** **• UCI Online Retail** **• Consumer Reviews of Amazon** **• Brazilian E-Commerce (Olist)** **• Sales Forecasting Superstore**
Documentos complementarios obligatorios: **Guías de práctica clínica (OMS, MinSalud), protocolos de bioseguridad, manuales diagnósticos o consentimientos informados.**	**Documentos complementarios obligatorios:** **Reglamentos académicos institucionales, protocolos de acompañamiento psicopedagógico, manuales de convivencia o guías de homologación.**	**Documentos complementarios obligatorios:** **Políticas de devoluciones y garantías de e-commerce, fichas técnicas de producto, acuerdos SLA o manuales de usuario.**

🛠️ SECCIÓN 3: Ruta de Aprendizaje y Flujo Metodológico (ACA 1)

PASO 1 Aprovisionamiento Bases de datos	PASO 2 Documentos e Ingesta	PASO 3 Pipeline de Chunking	PASO 4 Vectorización (Embeddings)	PASO 5 Búsqueda semantica
Crear tu base de datos vectorial para almacenar la información. Selección y despliegue del servicio de base de datos SQL y BD vectorial (Qdrant, Pinecone, Chroma, etc.).	Seleccionar los archivos de texto o PDF de tu pilar (Salud, Educación o Ventas). Recopilación y estructuración de los documentos (PDF/TXT) asociado a metadatos contextuales del dataset base seleccionado.	Como los documentos largos no se pueden procesar de golpe, se cortan en trozos pequeños llamados chunks.Estrategia de fragmentación (RecursiveCharacterTextSplitter o similar).	Transformar cada fragmento de texto en una lista de vectores que capture su significado semántico. utilizando el modelo seleccionado (Sentence-Transformers, Google Gemini embeddings 2, Embeddings Gemma2, QWen, Cohere u Ollama).	Crea una función de consulta donde captures una pregunta del usuario, la vectorices utilizando Gemini Embeddings 2 con configuración de consulta (RETRIEVAL_QUERY), ejecutes la búsqueda por similitud y recuperes los fragmentos más relevantes (Top-k) para alimentar tu sistema RAG.

📦 SECCIÓN 4: Entregables Oficiales del Proyecto (ACA 1)

Entregable	Formato	Descripción del Contenido
📓 **1. Notebook Técnico Reproducible**	**.ipynb**	Cuaderno (Jupyter o Google Colab) ordenado, reproducible y documentado que evidencia la ingesta de documentos, chunking, embeddings, subida masiva a la Base Vectorial Cloud seleccionada y consultas de validación semántica con cálculo de similitud.
📄 **2. Póster Sintético tipo Infografía**	**.pdf**	Póster visual y conciso en formato infografía que condensa: objetivo general, situación problema, pilar seleccionado, resumen del corpus documental, diagrama de la arquitectura cloud y stack tecnológico elegido, ejemplos de consultas semánticas y enlaces.
🎥 **4. Video de Sustentación**	**Enlace (3-5 min)**	Presentación ejecutiva del equipo: justificación del problema, explicación del corpus documental, justificación de las herramientas cloud seleccionadas y demostración funcional en tiempo real de consultas semánticas contra el clúster remoto.

📈 SECCIÓN 5: Rúbrica de Evaluación y Ponderaciones

Peso	Criterio de Evaluación	Descripción de Desempeño
20%	**1. Aprovisionamiento Cloud y Conectividad**	Despliegue y configuración correcta del almacén vectorial en el servicio seleccionado (Qdrant Cloud, Pinecone, ChromaDB, Weaviate, Supabase), con métrica de distancia apropiada y gestión segura de credenciales mediante variables de entorno (.env).
20%	**2. Calidad de Datos y Chunking**	Idoneidad del corpus de documentos complementarios seleccionado para el pilar, justificación técnica del tamaño de los fragmentos (chunks).
20%	**3. Generación de Embeddings e Indexación**	Integración idónea del modelo de representaciones semánticas seleccionado (HuggingFace, Google Gemini, Cohere, Gemma, Qwen u Ollama), vectorización eficiente e inserción por lotes (batch upsert) sin exceder la capa gratuita.
15%	**4. Validación de Búsqueda Semántica**	Rigor técnico en las pruebas de recuperación: consultas en lenguaje natural bien estructuradas, retorno consistente de los Top-k fragmentos más afines y análisis cuantitativo de las puntuaciones de similitud coseno.
15%	**5. Póster tipo Infografía (PDF)**	Claridad visual, síntesis conceptual de la arquitectura cloud de datos y el stack tecnológico implementado, diagramación profesional, cumplimiento formal de normas APA 7 y enlaces operativos.
10%	**6. Sustentación en Video**	Capacidad de síntesis, dominio técnico de los conceptos de bases de datos vectoriales y computación en la nube, y demostración funcional dentro del tiempo estipulado (3 a 5 minutos).

📋 Directrices Clave de Envío y Seguridad Cloud:

• Gestión Segura de Credenciales: Las API Keys del proveedor cloud vectorial seleccionado deben ser leídas exclusivamente a través de variables de entorno (.env). No incluir Api keys secretos hardcodeados en los notebooks o repositorios públicos.

• Reproducibilidad: El Notebook debe ejecutarse de forma secuencial sin errores de principio a fin, incluyendo comentarios metodológicos y visualización del Top-k de fragmentos recuperados.

• Póster tipo Infografía: Debe entregarse en PDF exportado en alta resolución, siguiendo el estándar visual de divulgación científica y con hipervínculos funcionales al repositorio y video.

📚 Referencias Bibliográficas (Normas APA 7)

Fuentes de los datasets base, literatura fundacional de arquitecturas RAG y documentación técnica oficial de los proveedores y librerías cloud:

Aljarah, I. (2016). *xAPI-Edu-Data (Student Academic Performance)* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/aljarah/xAPI-Edu-Data

Chase, H. (2022). *LangChain: Building applications with LLMs through composability and data augmented generation.* https://github.com/langchain-ai/langchain

Chen, D. (2015). *UCI Online Retail Dataset* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/352/online+retail

Cortez, P. (2014). *UCI Student Performance Dataset* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/320/student+performance

Datafiniti. (2019). *Consumer Reviews of Amazon Products* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/datafiniti/consumer-reviews-of-amazon-products

Elkharoua, R. (2024). *Students Performance in Exams Dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/rabieelkharoua/students-performance-dataset

Janosi, A., Steinbrunn, R., Pfisterer, M., & Detrano, R. (1988). *UCI Heart Disease Dataset* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/45/heart+disease

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). *Retrieval-augmented generation for knowledge-intensive NLP tasks.* Advances in Neural Information Processing Systems, 33, 9459–9474. https://arxiv.org/abs/2005.11401

Liu, J. (2022). *LlamaIndex: A data framework for your LLM applications.* https://github.com/run-llama/llama_index

Luque, G. (2021). *Sales Forecasting - Retail Superstore* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/rohitsahoo/sales-forecasting

Martins, M. V., Real, M. B., Machado, J., & Becker, A. (2021). *UCI Predict Students Dropout and Academic Success* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

Mooney, P. (2018). *Chest X-Ray Images (Pneumonia)* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia

Olist. (2018). *Brazilian E-Commerce Public Dataset by Olist* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

Pinecone Systems, Inc. (2024). *Pinecone Vector Database Documentation.* https://docs.pinecone.io/

Qdrant Solutions GmbH. (2024). *Qdrant Documentation: Vector Search Engine & Cloud Database.* https://qdrant.tech/documentation/

Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence embeddings using Siamese BERT-networks.* Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP). https://arxiv.org/abs/1908.10084

Tschandl, P. (2018). *Skin Cancer MNIST: HAM10000* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000

Wolberg, W., Street, N., & Mangasarian, O. (1995). *UCI Breast Cancer Wisconsin (Diagnostic)* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic