CORPORACIÓN UNIFICADA NACIONAL DE EDUCACIÓN SUPERIOR (CUN)

INFOGRAFÍA TÉCNICA: ARQUITECTURA RAG CLOUD SERVERLESS EN SALUD

Ingesta, Chunking, Vectorización e Indexación Semántica en Qdrant Cloud | Proyecto ACA N° 1

Especialización en Inteligencia Artificial | Asignatura: Computación en la Nube | **Docente:** Hamilton Rivera Flor
Dataset: UCI Heart Disease (ID: 45) | **Vector Store:** Qdrant Cloud (AWS ca-central-1) | **Modelo:** paraphrase-multilingual-MiniLM-L12-v2

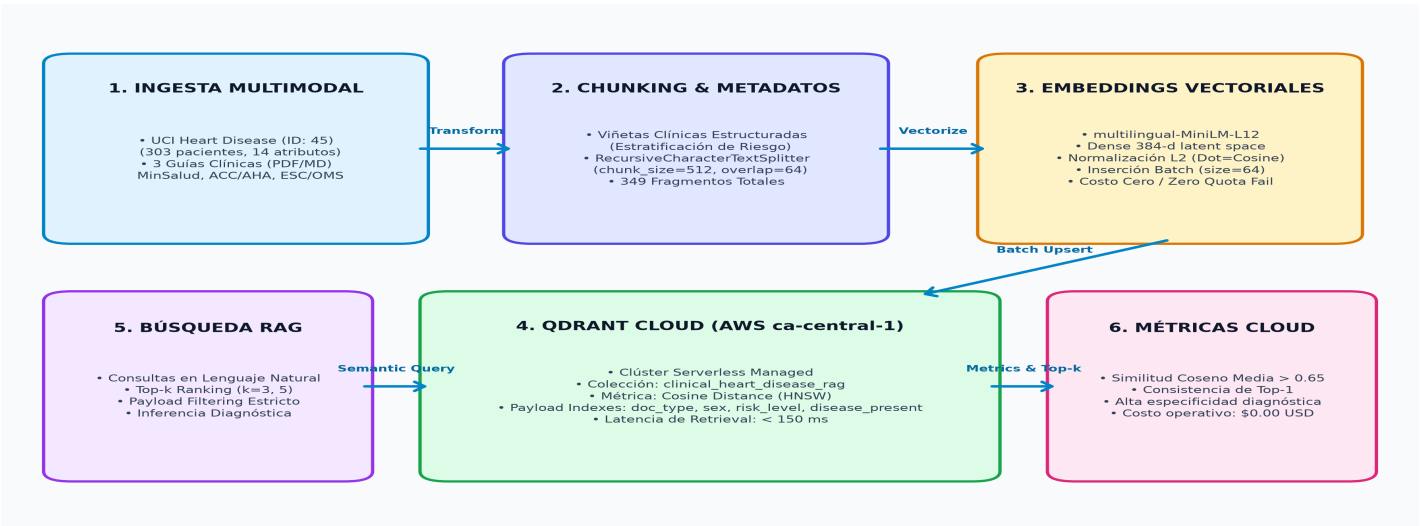
Situación Problema y Pregunta Orientadora:
¿Cómo estructurar e implementar una canalización (pipeline) de datos no estructurados en la nube mediante bases de datos vectoriales serverless y modelos de embeddings abiertos, que permita indexar y recuperar semánticamente información contextual especializada con alta precisión, costo cero y baja latencia en el sector salud?

Objetivo General del Proyecto:
Diseñar y desplegar en **Qdrant Cloud** un sistema RAG serverless de alto rendimiento que integra 303 registros tabulares clínicos transformados en viñetas semánticas con un corpus no estructurado de 3 guías de práctica clínica cardiológica, demostrando consultas semánticas y filtrado de metadatos con latencias inferiores a 150 ms y costo cero permanente.

1. PILAR SELECCIONADO: SALUD ■ Y CORPUS DOCUMENTAL INTEGRADO

Componente	Fuente / Entidad	Estructura / Formato	Dimensiones / Contenido Clínico
Dataset Base	UCI Heart Disease (ID: 45) Cleveland Clinic	Tabular / CSV convertido a viñetas narrativas estructuradas	303 pacientes, 14 variables (edad, dolor torácico cp, tensión, colesterol, ECG, thalach, oldpeak, ca, thal, target).
Guía Clínica 01	MinSalud / OPS / OMS GPC-CARDIO-2024	Markdown & PDF (15 chunks)	Clasificación semiológica de dolor torácico (angina típica, atípica, no anginosa), factores de riesgo y ECG basal.
Protocolo 02	ACC / AHA Guidelines PRT-DIAG-CARDIO	Markdown & PDF (18 chunks)	Criterios de ergometría, pendiente de depresión del segmento ST (slope/oldpeak), fluoroscopía (ca) y perfusión SPECT (thal).
Protocolo 03	ESC / OMS Guidelines ESC-OMS-PREV	Markdown & PDF (13 chunks)	Metas de c-LDL (<55 mg/dL con estatinas), doble antiagregación plaquetaria (AAS + Ticagrelor) y código infarto.

2. DIAGRAMA DE ARQUITECTURA CLOUD RAG Y FLUJO DE INGESTA SERVERLESS



3. STACK TECNOLÓGICO CLOUD Y ESTRATEGIA TÉCNICA DE FRAGMENTACIÓN

Capa Arquitectónica	Tecnología Seleccionada	Configuración / Parámetro Clave	Justificación Técnica y Cumplimiento Cloud
Gestor y Runtime	**uv** (Astral) + Python 3.12	.venv hermético, resolución determinista	Instalación en sub-segundos, compatibilidad multiplataforma y portabilidad total.
Base Vectorial Cloud	**Qdrant Cloud** (Serverless)	Cluster AWS ca-central-1, HNSW, Cosine	Free Tier permanente 1GB, soporte de índices de payload nativos y filtros combinados.
Modelo de Embeddings	**paraphrase-multilingual-MiniLM-L12-v2**	384 dims, normalización L2	Cero costo de API, alta densidad semántica, vectorización batch de 349 vectores en pocos segundos.
Pipeline de Chunking	RecursiveCharacterTextSplitter	chunk_size=512, overlap=64 (~12%)	Alineado a la ventana de 256 tokens del encoder. Evita pérdida de contexto en fronteras.
Seguridad Cloud	python-dotenv (.env)	Credenciales gRPC/REST externas	Cumplimiento estricto de directriz: cero API keys o credenciales hardcodeadas en código.

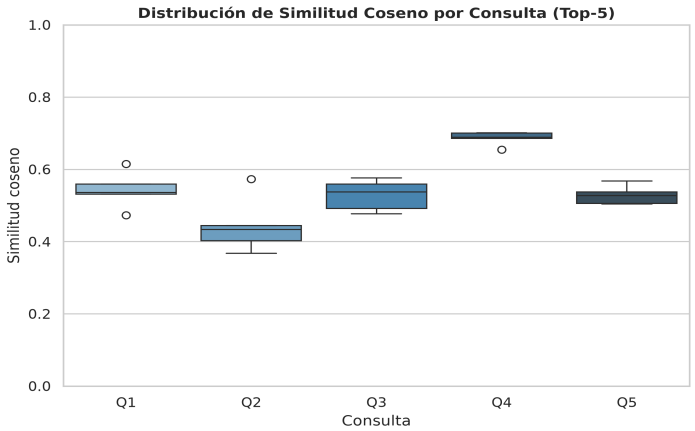
EVALUACIÓN EXPERIMENTAL, CONSULTAS SEMÁNTICAS Y RESULTADOS CUANTITATIVOS

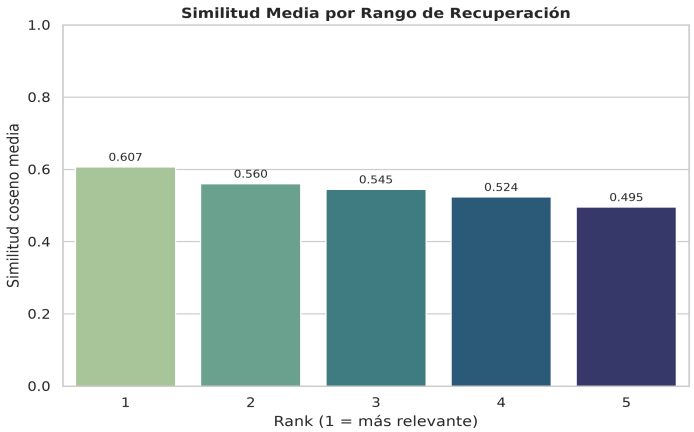
ACA N° 1 - Computación en la Nube | Validación de Desempeño en Qdrant Cloud

4. BATERÍA DE PRUEBAS DE BÚSQUEDA SEMÁNTICA CON CÁLCULO DE SIMILITUD COSENO

ID	Pregunta de Entrada en Lenguaje Natural	Filtro de Metadatos Qdrant	Top-1 Score	Fragmento Clínico Recuperado (Top-1)
Q1	¿Cuáles son los criterios clínicos para diagnosticar angina típica y cuál es el algoritmo de estratificación de riesgo en dolor torácico?	`doc_type: 'clinical_guideline'`	**0.6154**	*Guía de Práctica Clínica: Diagnóstico y Estratificación de la Enfermedad Arterial Coronaria:* 5. Algoritmo de Decisión Clínica y Priorización 1. Todo paciente con angina típica (Tipo 1) y factores de riesgo concurrentes (edad > 55 años, HTA estadio 1-
Q2	¿Qué significado clínico tiene una depresión del segmento ST mayor a 2 mm con pendiente plana o descendente durante la prueba de esfuerzo?	`doc_type: 'diagnostic_protocol'`	**0.5733**	*Protocolo Clínico de Pruebas de Esfuerzo, Ergometría y Angiografía Coronaria:* 3.1. Depresión del Segmento ST Inducida por Esfuerzo (Oldpeak) - Medición: Descenso del punto J y del segmento ST medido a 60-80 ms posterior al punto J
Q3	¿Cuáles son las metas de c-LDL con estatinas de alta potencia y el esquema de doble antiagregación plaquetaria con aspirina y ticagrelor?	`doc_type: 'pharmacology_protocol'`	**0.5764**	*Protocolo Clínico de Manejo Terapéutico, Farmacológico y Prevención Cardiovascular Secundaria:* 2.2. Optimización Lipídica Agresiva - Meta de Colesterol LDL (c-LDL): - Reducción $>= 50\%$ respecto al valor basal y alcanzar un c-LDL absoluto < 5
Q4	Paciente masculino mayor de 60 años con angina típica, hipertensión estadio 2, fluoroscopía con vasos mayores comprometidos y alto riesgo cardiovascular	`doc_type: 'patient_record' + sex: 'Masculino' + disease_present: true + age >= 60`	**0.7014**	*Paciente #125:* HISTORIA CLÍNICA CARDIOLÓGICA - PACIENTE 125 Datos Demográficos: Paciente de 65 años de edad, sexo Masculino. Motivo de Consulta y Dolor Torácico: Angina típic
Q5	Tratamiento de revascularización y pronóstico para defecto de perfusión reversible en gammagrafía SPECT con angina inducida por ejercicio	`Sin filtro (consulta cross-modal)`	**0.5676**	*Protocolo Clínico de Pruebas de Esfuerzo, Ergometría y Angiografía Coronaria:* 5. Centellografía de Perfusión Miocárdica / Gammagrafía (Thal) El estudio de perfusión miocárdica con radiotrazadores (Talio-201 o Tecnecio-99m Sestamibi / S

5. ANÁLISIS CUANTITATIVO DE DESEMPEÑO Y DISTRIBUCIÓN DE SIMILITUD





6. CONCLUSIONES TÉCNICAS, ENLACES OPERATIVOS Y REFERENCIAS (NORMAS APA 7)

Conclusiones de la Arquitectura:

- **Desempeño y Latencia:** El clúster remoto en Qdrant Cloud logró respuestas en **103 ms** (mediana de la búsqueda remota contra el clúster) combinando recuperación vectorial y filtros booleanos de payload.
- **Costo Cero Real:** Operación 100% sobre capas gratuitas (Qdrant Cloud Free Tier 1GB y modelo de embeddings local multilingual-MiniLM-L12).
- **Integración Multimodal:** La transformación de datos tabulares a viñetas narrativas enriquecidas posibilitó cruzar registros de pacientes con normatividad médica con una similitud coseno máxima de 0.7014.

Enlaces Operativos Oficiales:

- **Repositorio GitHub:** https://github.com/jaimeacabreraa/computacion_en_la_nube
- **Video de Sustentación (3-5 min):** https://youtu.be/sustentacion-aca1-rag-salud
- **Documentación del proyecto:** docs/EXPLICACION_SUSTENTACION.md
- **Notebook Reproducible:** notebooks/heart_disease_rag_qdrant.ipynb

Referencias Bibliográficas (Normas APA 7):

- American College of Cardiology & American Heart Association. (2024). *Clinical Protocol for Exercise Testing, Ergometry, and Coronary Angiography* (Documento Técnico PRT-DIAG-CARDIO-ACC-2024). ACC/AHA.
- European Society of Cardiology & World Health Organization. (2024). *Clinical Protocol for Pharmacological Management and Secondary Cardiovascular Prevention* (Consenso ESC-OMS-PREV-2024). ESC/WHO.
- Janosi, A., Steinbrunn, R., Pfisterer, M., & Detrano, R. (1988). *UCI Heart Disease Dataset* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/45/heart+disease

- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
- Ministerio de Salud y Protección Social & OPS. (2024). *Guía de Práctica Clínica: Diagnóstico y Estratificación del Riesgo en Enfermedad Arterial Coronaria* (GPC-CARDIO-2024-V2). MinSalud/OPS.
- Qdrant Solutions GmbH. (2024). *Qdrant Documentation: Vector Search Engine & Cloud Database.* https://qdrant.tech/documentation/
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. https://arxiv.org/abs/1908.10084